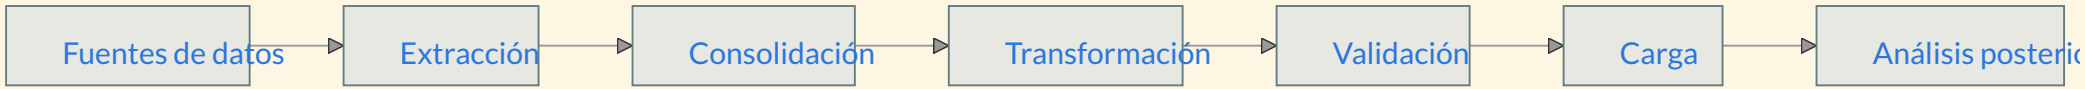
INTRODUCCIÓN A PROCESOS ETL

Clase 1

Diplomatura en Ingeniería de Datos e IA - Instituto Balseiro



FUNDAMENTOS DE CIENCIA DE DATOS Y PROCESOS ETL



La ciencia de datos es un proceso, no una herramienta.

Empieza con una pregunta:

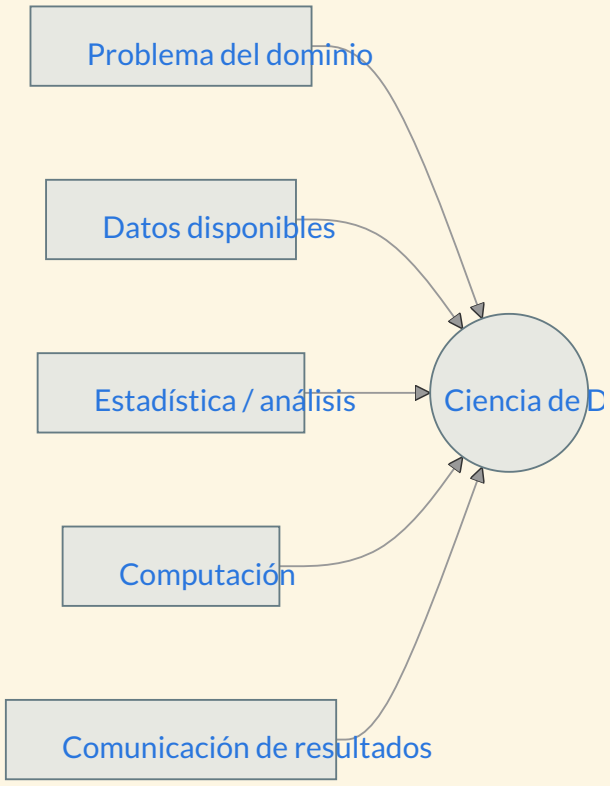
> ¿Qué queremos saber, decidir, explicar o predecir?

EJEMPLOS

- ¿Qué productos se venden juntos?
- ¿Qué clientes abandonan un servicio?
- ¿Qué pacientes faltan a sus turnos?
- ¿Qué zonas tienen mayor demanda?
- ¿Qué errores aparecen más frecuentemente en un sistema?
- ¿Qué indicadores anticipan una caída de ventas?

2. ALCANCE DE LA CIENCIA DE DATOS

La ciencia de datos puede verse como una intersección entre varias áreas:



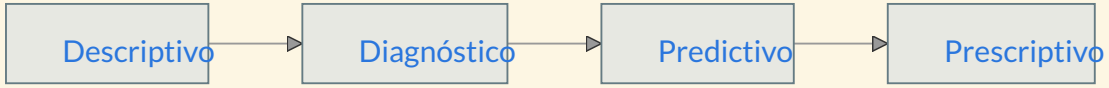
No alcanza con saber programar. Tampoco alcanza con saber estadística. Hace falta comprender el **problema** y el **contexto**.

QUÉ PUEDE HACER LA CIENCIA DE DATOS

Puede ayudar a:

- Describir lo que pasó.
- Detectar patrones.
- Medir indicadores.
- Encontrar anomalías.
- Comparar grupos.
- Predecir comportamientos.
- Recomendar acciones.
- Automatizar decisiones repetitivas.

NIVELES DE ANÁLISIS



Ventas

Nivel	Pregunta
Descriptivo	¿Cuánto vendimos este mes?
Diagnóstico	¿Por qué bajaron las ventas?
Predictivo	¿Cuánto venderemos el mes próximo?
Prescriptivo	¿Qué promociones conviene lanzar?

Salud

Nivel	Pregunta
Descriptivo	¿Cuántas consultas se atendieron?
Diagnóstico	¿Por qué aumentaron las demoras?
Predictivo	¿Qué pacientes tienen más riesgo de faltar?
Prescriptivo	¿A quién conviene enviar recordatorio?

FASES DE UN PROYECTO DE CIENCIA DE DATOS

1. Definición del problema
2. Recolección de datos
3. Exploración inicial
4. Limpieza y transformación
5. Análisis o modelado
6. Evaluación
7. Comunicación
8. Puesta en producción o uso operativo
9. Monitoreo

1. DEFINICIÓN DEL PROBLEMA

Antes de tocar los datos hay que entender:

- ¿Cuál es la pregunta?
- ¿Quién necesita la respuesta?
- ¿Qué decisión se va a tomar?
- ¿Qué datos existen?
- ¿Qué restricciones hay?
- ¿Qué significa que el resultado sea útil?

EJEMPLO:

No es lo mismo decir:

> “Queremos analizar clientes.”

que decir:

> “Queremos identificar clientes con alta probabilidad de abandonar el servicio durante los próximos 30 días, para intervenirlos con una campaña de retención.”

La segunda formulación permite definir datos, métricas y acciones.

2. RECOLECCIÓN DE DATOS

- Planillas Excel.
- Archivos CSV.
- APIs.
- Bases de datos.
- Formularios.
- Sistemas administrativos.
- Sensores.
- Logs.
- Documentos.
- Imágenes.

2. RECOLECCIÓN DE DATOS

En esta etapa aparece la primera pregunta práctica:

> ¿Dónde están los datos y cómo accedo a ellos?

3. EXPLORACIÓN INICIAL

Antes de transformar datos conviene **mirarlos**.

Preguntas típicas:

- ¿Cuántas filas hay?
- ¿Cuántas columnas?
- ¿Qué representa cada columna?
- ¿Qué tipos de datos hay?
- ¿Hay valores faltantes?
- ¿Hay duplicados?
- ¿Hay valores imposibles?
- ¿Hay fechas mal cargadas?

En Python/Pandas esto después se traduce en:

```
df.head()
df.info()
df.describe()
df.isna().sum()
df.duplicated().sum()
df["columna"].value_counts()
```

4. LIMPIEZA Y TRANSFORMACIÓN

- Renombrar columnas.
- Convertir tipos de datos.
- Corregir fechas.
- Eliminar duplicados.
- Manejar datos faltantes.

- Unificar categorías.
- Normalizar unidades.
- Corregir errores de carga.
- Filtrar registros inválidos.
- Crear nuevas columnas.
- Unir tablas.

> La limpieza y transformación es la parte más importante, aunque menos glamorosa, de la ciencia de datos.

Ejemplo:

```
"Bariloche", "S. C. de Bariloche", "San Carlos Bariloche"
```

Todas podrían representar la misma ciudad, pero para la computadora son tres valores distintos.

5. ANÁLISIS O MODELADO

Recién acá entran los análisis más visibles:

- Tablas resumen.
- Gráficos.
- Indicadores.
- Correlaciones.
- Segmentaciones.

...

- Modelos predictivos.
- Sistemas de recomendación.
- Clasificadores.
- Detección de anomalías.

> Pero **la calidad** del análisis depende directamente de **la calidad** del dato preparado.

6. EVALUACIÓN

Hay que evaluar si el resultado sirve.

En un análisis descriptivo:

- ¿Los números tienen sentido?
- ¿Coinciden con otras fuentes?
- ¿Hay sesgos?
- ¿Hay datos incompletos?

EN UN MODELO PREDICTIVO:

- ¿Predice bien?
- ¿Con qué métrica?
- ¿Funciona igual en distintos grupos?
- ¿Tiene errores aceptables?
- ¿Se puede explicar?

7. COMUNICACIÓN

Los resultados deben comunicarse según la audiencia.

No es lo mismo hablarle a:

- Un equipo técnico.
- Una gerencia.
- Un cliente.
- Un equipo médico.
- Un usuario final.

La comunicación puede tomar la forma de:

- Reporte.
- Dashboard.
- Presentación.
- Notebook.
- API.
- Aplicación.
- Alerta automática.

8. PUESTA EN PRODUCCIÓN

Un análisis puede quedar como informe, pero también puede transformarse en un proceso operativo.

Ejemplos:

- Un dashboard que se actualiza todos los días.
- Un pipeline ETL automático.
- Un modelo que predice demanda.
- Una alerta cuando aparece un valor anómalo.
- Un sistema que recomienda productos.

9. MONITOREO

Cuando los procesos pasan a producción, hay que monitorearlos.

- ¿Llegaron los datos de hoy?
- ¿Falló alguna fuente?
- ¿Cambió el formato del archivo?
- ¿Aparecieron valores inesperados?
- ¿El modelo sigue funcionando bien?
- ¿Las métricas cambiaron?

Esto introduce la idea de que ciencia de datos no es solamente análisis puntual, sino también sistemas vivos.

DIFERENCIAS ENTRE ARQUITECTURA, INGENIERÍA Y CIENCIA DE DATOS

ARQUITECTURA DE DATOS

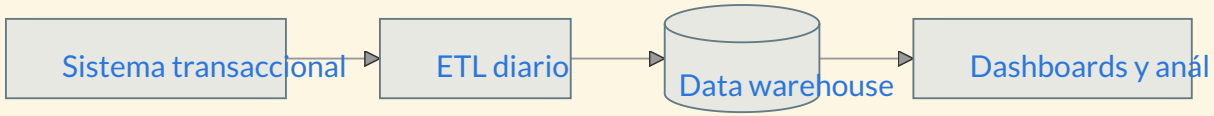
La arquitectura define el diseño general del ecosistema.

Se pregunta:

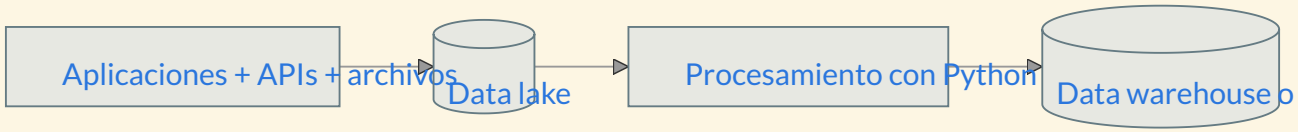
- ¿Dónde viven los datos?
- ¿Cómo se conectan los sistemas?
- ¿Qué repositorios se usan?
- ¿Qué datos son sensibles?
- ¿Quién puede acceder?
- ¿Cómo se escala?
- ¿Cómo se gobiernan los datos?

Ejemplo:

Una organización decide tener:



O bien:



La arquitectura no necesariamente programa cada proceso, pero define el mapa.

INGENIERÍA DE DATOS

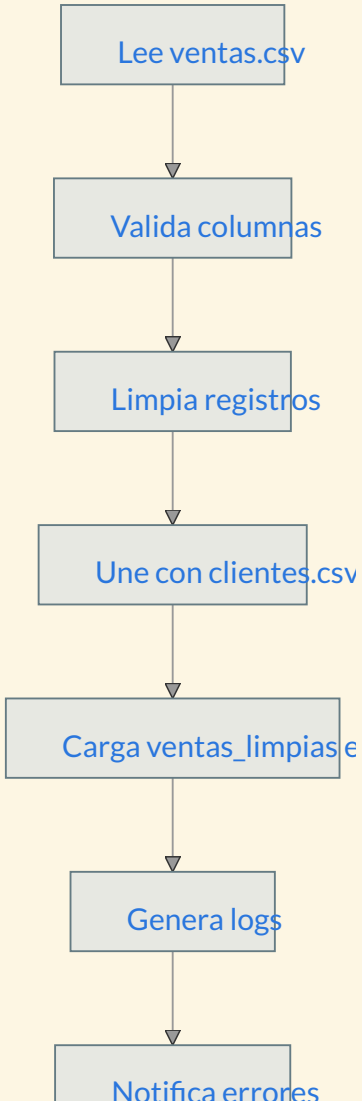
La ingeniería construye y mantiene los flujos de datos.

Se ocupa de:

- Extraer datos.
- Automatizar procesos.
- Transformar datos.
- Controlar errores.
- Crear pipelines.
- Optimizar cargas.
- Mantener disponibilidad.
- Documentar flujos.

Ejemplo:

Un ingeniero de datos arma un proceso que:



CIENCIA DE DATOS

La ciencia de datos usa los datos para responder preguntas.

Se ocupa de:

- Explorar datos.
- Formular hipótesis.
- Calcular indicadores.
- Visualizar resultados.
- Entrenar modelos.
- Interpretar resultados.
- Comunicar hallazgos.

Ejemplo:

Con la tabla `ventas_limpias`, un científico de datos analiza:

- Productos más vendidos.
- Estacionalidad.
- Segmentos de clientes.
- Predicción de demanda.
- Recomendación de productos complementarios.

> La arquitectura diseña el sistema de datos. La ingeniería hace que los datos lleguen limpios y confiables. La ciencia de datos usa esos datos para producir conocimiento o predicciones.

HERRAMIENTAS UTILIZADAS

OPCIÓN 1: ANACONDA (MINICONDA)

Ventajas:

- Fácil para principiantes.
- Incluye Jupyter.
- Maneja entornos.
- Viene con muchas librerías.

Desventajas:

- Pesado.
- A veces confunde con entornos múltiples.

Opción 2: Python + (`venv` + `pip`) o `poetry` o `uv`

Ventajas:

- Más liviano.
- Más estándar para desarrollo.
- Menos dependencia de Anaconda.

Desventajas:

- Requiere más manejo de terminal.

OPCIÓN 3: GOOGLE COLAB

Ventajas:

- No requiere instalación local.
- Funciona desde navegador.
- Bueno para evitar problemas de setup.

Desventajas:

- Depende de internet.
- Menos control del entorno.
- Manejo de archivos diferente.

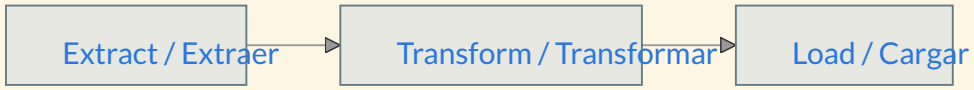
FASES DE UN PROYECTO DE CIENCIA DE DATOS

1. Definición del problema
2. Recolección de datos
3. **Exploración inicial**
4. **Limpieza y transformación**
5. Análisis o modelado
6. Evaluación
7. Comunicación
8. Puesta en producción o uso operativo
9. Monitoreo

CONCEPTOS DE ETL

DEFINICIÓN

ETL significa:



Es el proceso mediante el cual se toman datos desde una o varias fuentes, se los prepara y se los carga en un destino.

IDEA CENTRAL

> ETL convierte datos crudos en datos utilizables.

7. EXTRACT: EXTRACCIÓN DE DATOS

Extraer significa obtener datos desde una fuente.

Fuentes frecuentes:

```
Archivos CSV
Archivos Excel
JSON
TXT
YAML
Bases de datos
APIs
Logs
Formularios web
Sistemas administrativos
```

Ejemplo básico:

```
ventas.csv
clientes.csv
productos.json
cotizacion_dolar_api
```

Preguntas importantes:

- ¿Dónde están los datos?
- ¿En qué formato vienen?
- ¿Con qué frecuencia se actualizan?
- ¿Quién los genera?
- ¿Son confiables?
- ¿Están completos?
- ¿Hay permisos para usarlos?

8. TRANSFORM: TRANSFORMACIÓN DE DATOS

Llevar los datos a un estado más útil y confiable. Operaciones típicas:

- Cambiar nombres de columnas.
- Convertir tipos.
- Estandarizar formatos.
- Corregir inconsistencias.
- Eliminar duplicados.
- Validar reglas.
- Unir fuentes.
- Agregar información.
- Calcular nuevas variables.

Ejemplo:

A partir de:

fecha	cliente	producto	cant	precio
13/06/26	ana	mouse	2	15
07-26-2026	Juan	Teclado	1	50 $

Transformar a:

fecha	cliente	producto	cantidad	precio_unitario	total
2026-06-13	Ana	Mouse	2	15	30
2026-07-26	Juan	Teclado	1	50	50

LOAD: CARGA DE DATOS

Cargar significa guardar los datos transformados en un destino.

Destinos posibles:

- Otra planilla.
- Un CSV limpio.
- Una base de datos.
- Un data warehouse.
- Un data lake.
- Un dashboard.
- Una tabla analítica.
- Un sistema de reportes

Ejemplo:

```
ventas_limpias.csv
ventas_limpias.parquet
tabla ventas_analiticas en PostgreSQL
tabla en BigQuery
directorio en un data lake
```

EXTRACCIÓN Y CONSOLIDACIÓN DESDE DIVERSAS FUENTES

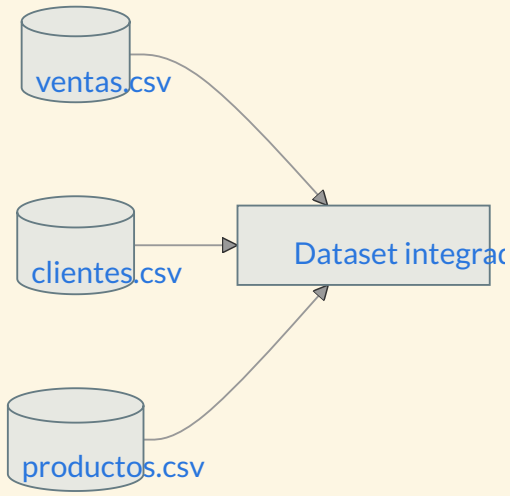
Consolidar significa juntar datos dispersos en una vista coherente.

Ejemplo:

```
ventas.csv
clientes.csv
productos.csv
```

Cada archivo por separado dice algo parcial.

Al consolidarlos:



podemos responder preguntas más ricas:

- ¿Qué compró cada cliente?
- ¿Desde qué ciudad?
- ¿Qué categoría de producto?
- ¿Cuál fue el total?

PROBLEMAS TÍPICOS AL CONSOLIDAR

- Claves que no coinciden.
- IDs faltantes.
- Duplicados.
- Nombres escritos de varias maneras.
- Fechas en formatos distintos.
- Diferentes granularidades.

Ejemplo de granularidad:

```
ventas.csv: una fila por venta
clientes.csv: una fila por cliente
productos.csv: una fila por producto
```

Hay que entender qué representa cada fila.

INTEGRIDAD Y CONSISTENCIA DE DATOS

INTEGRIDAD

La integridad tiene que ver con que los datos respeten ciertas reglas.

Ejemplos:

- Una venta debe tener fecha.
- Una cantidad no puede ser negativa.
- Un precio no puede ser menor que cero.
- Un cliente_id debe existir en la tabla de clientes.
- Una fecha de nacimiento no puede estar en el futuro.

CONSISTENCIA

La consistencia tiene que ver con que los datos no se contradigan entre sí.

Ejemplos:

- La misma ciudad no debería aparecer como `CABA`, `Capital Federal`, `Buenos Aires CABA` sin criterio.
- La moneda debería estar claramente definida.
- Las fechas deberían tener el mismo formato.
- Las categorías deberían estar normalizadas.
- Un producto no debería tener dos nombres distintos sin razón.

EJEMPLOS DE REGLAS

```
cantidad > 0
precio_unitario >= 0
fecha <= fecha_actual
cliente_id no nulo
producto_id existe en productos
email contiene "@"
provincia pertenece a lista válida
```